Máster Internacional en Inteligencia Artificial para la Arquitectura y Construcción

Módulo 4 – Tema 3 (M4T3) – Programación e Inteligencia Artificial para el Sector AECO

Título: Visión Computacional

Docente: Pablo Aumente

Alumno: Victor Daniel Peña Chavez

Fecha: 08 / Marzo / 2026

M4T3 – Prototipo AECO CV (YOLOv8)

Detección de EPP en obra mediante visión computacional

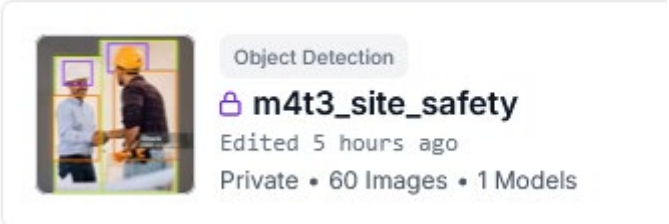

Clases: person, hardhat, safety_vest, no_hardhat, no_safety_vest
Modelo: YOLOv8n (imgsz 640, epochs 30)

Este prototipo busca detectar uso de EPP en imágenes de obra con YOLOv8, clasificando presencia de casco y chaleco, y también casos de incumplimiento.

Fuente imágenes: [iStock / Roboflow / elaboración propia]

Problema y objetivo

- En obra, el control de **EPP** suele ser **manual** y no escalable.
- Se necesita **detección automática** de **casco y chaleco** desde imágenes.
- **Objetivo:** identificar **cumplimiento/incumplimiento** y apoyar el control de seguridad.
- **Salida esperada:** detecciones por clase + evidencia visual (predicciones) + métricas.

Lo planteo como un primer paso hacia un flujo de inspección: capturo imágenes, el modelo detecta EPP y eso alimenta indicadores o alertas por zona/fecha.

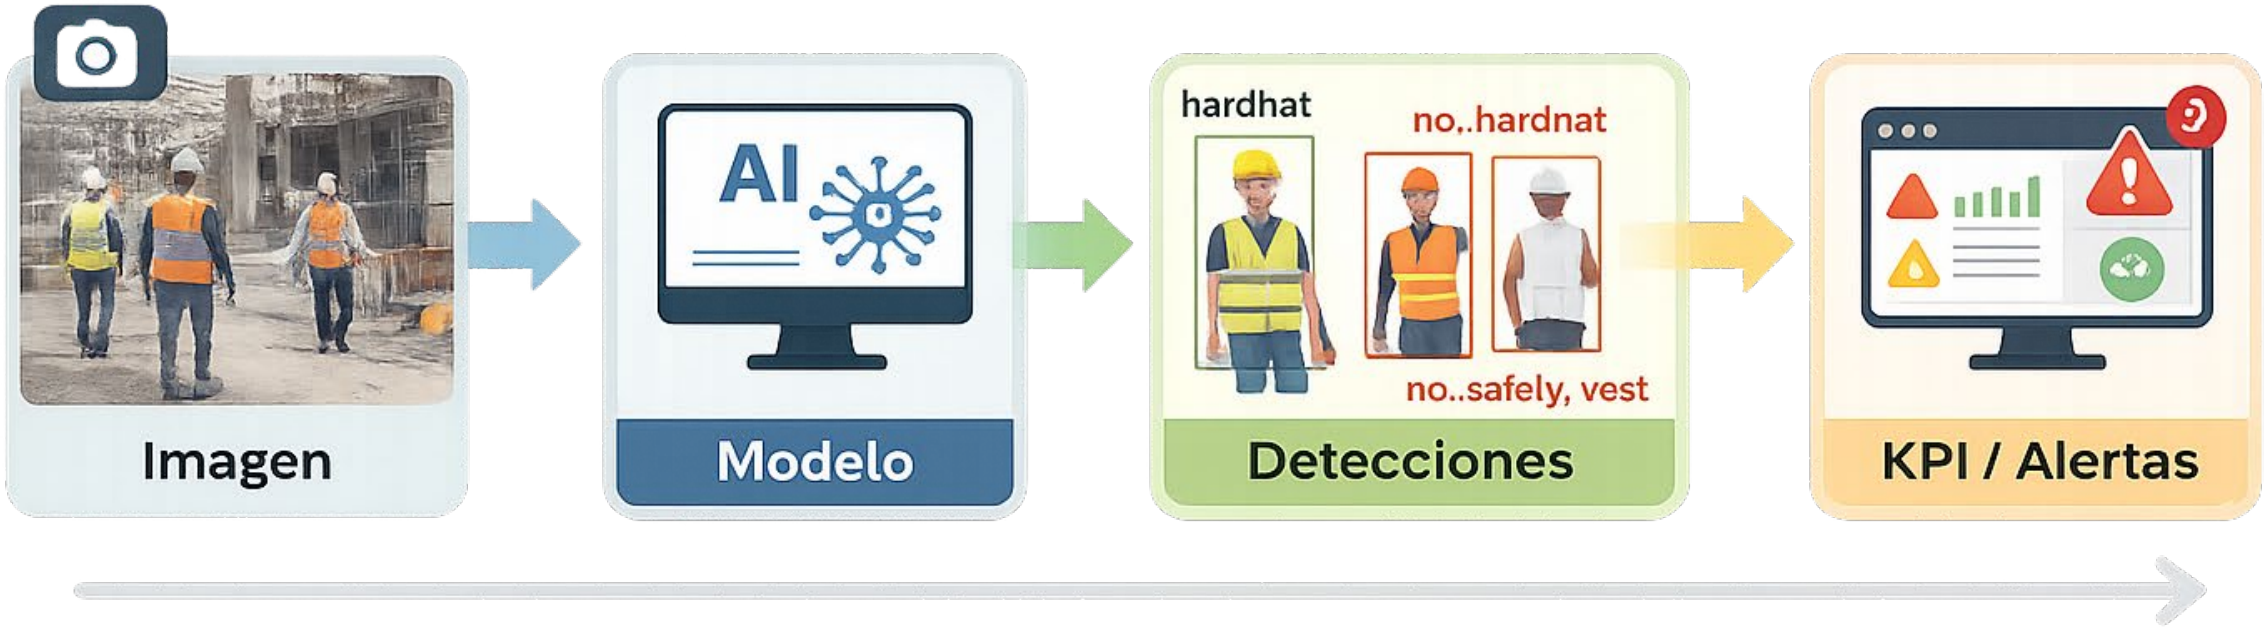

Dataset

- Fuente: **Roboflow dataset** (formato YOLO)
- Total: **60 imágenes**
    - **Train:** 48 (80%)
    - **Valid:** 12 (20%)
- Configuración de entrenamiento:
    - **imgsz:** 640
    - **epochs:** 30
    - **modelo:** YOLOv8n
- Clases: person, hardhat, safety_vest, no_hardhat, no_safety_vest

Es un dataset pequeño, útil para prototipado rápido. Eso impacta especialmente en el recall, sobre todo con objetos pequeños u ocluidos.

roboflow Dataset > Version 1

+ Dataset Upgrade

Overview
Annotate
Health Check
Transform
Train

construction-ppe-detection

Search images...

YOLO Version 1

Total Images	48	12	0
	80 (30%)	20 (20%)	0 (0%)

Train: 48
Valid: 12 (20%)
Test: 0 (0%)

Download

5 Classes / 771 Annotations

Class	Train	Valid	Total
person	161 (79%)	28 (66%)	189 (76%)
hardhat	84 (41%)	21 (50%)	105 (42%)
safety_vest	83 (41%)	20 (48%)	103 (41%)
no_hardhat	33 (16%)	5 (12%)	38 (15%)
no_safety_vest	8 (4%)	1 (2%)	9 (3%)

person hardhat safety_vest no_hardhat no_safety_vest

Pipeline (flujo de trabajo)

Diagrama (ideal en 5 bloques)

1. **Etiquetado** (clases + bounding boxes)
2. **Versionado** del dataset (Roboflow)
3. **Entrenamiento** YOLOv8
4. **Validación** (curvas + confusion matrix)
5. **Inferencia** (valid + imágenes nuevas)

- Evidencias: **curvas de entrenamiento**, **confusion matrix**, **predicciones**
- Comparación entre **validación** y **escenas nuevas** (generalización)

Dejo trazabilidad: dataset versionado, parámetros de entrenamiento y evidencias de evaluación. El objetivo es replicabilidad, no solo ‘que funcione una vez’.

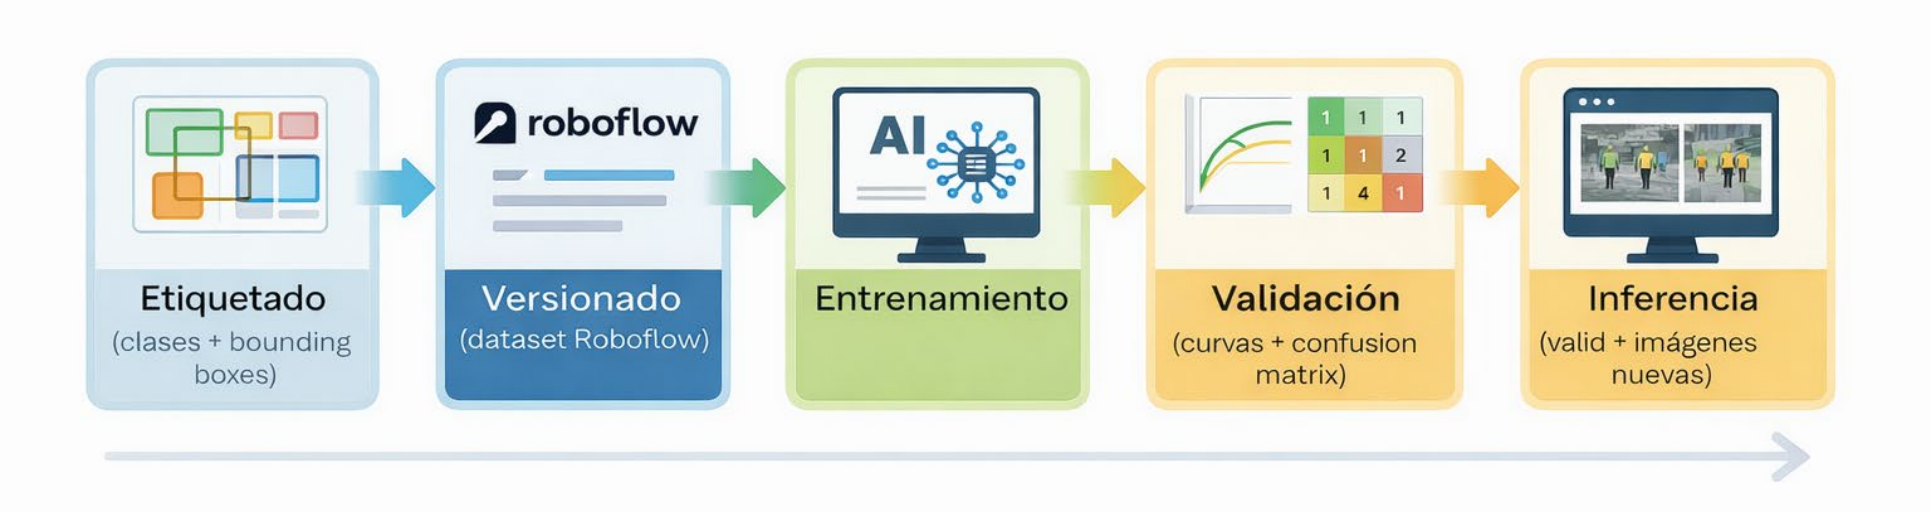

Resultados (validación)

Métricas (en formato grande, tipo tarjeta)

- **Precision:** 0.9884
- **Recall:** 0.1728
- **mAP@0.50:** 0.5371
- **mAP@0.50:0.95:** 0.3047

Lectura rápida

- **Alta precisión**: pocas falsas detecciones.
- **Bajo recall**: se están escapando detecciones (faltantes).

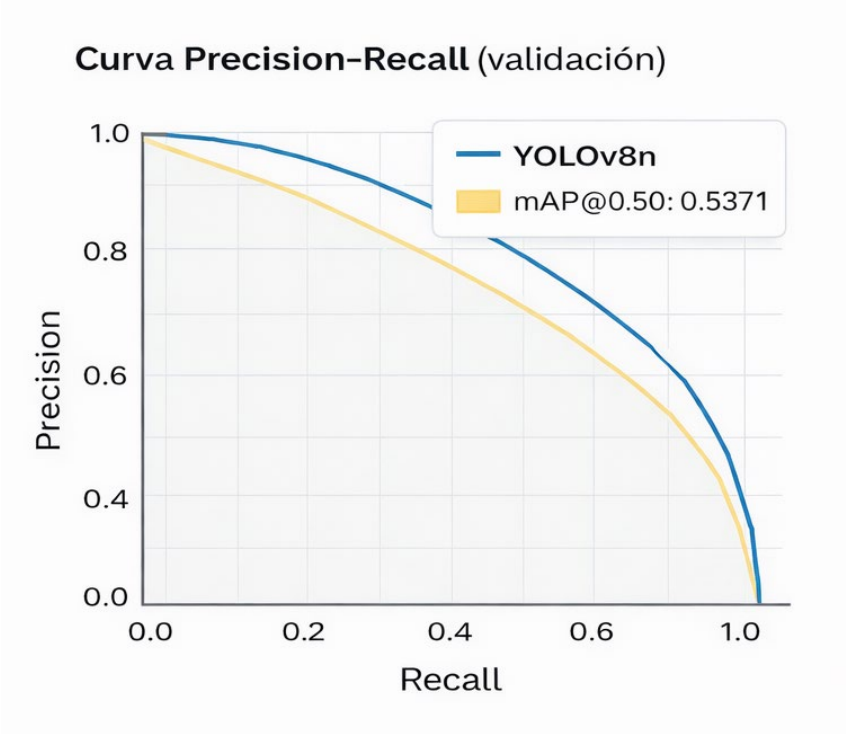

Los números indican que cuando detecta, suele acertar (precision alta), pero detecta poco (recall bajo). Para seguridad, el recall suele ser crítico porque no quiero ‘perder’ incumplimientos.

Métricas sobre valid (12 imgs). mAP: promedio sobre clases.

Precision	Recall	mAP@0.50
0.9884	0.1728	0.5371

mAP@0.50	0.5371	mAP@0.50:0.95

Confusion Matrix (validación)

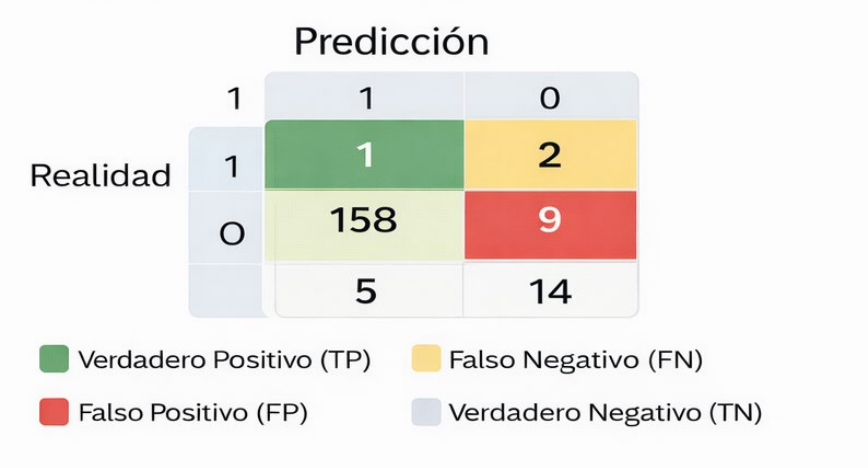

Interpretación + próximos pasos

Interpretación

- **Dataset pequeño** → baja cobertura de escenarios reales.
- **Objetos pequeños / oclusiones** (casco/chaleco) → detección más difícil.
- Posible **desbalance** entre clases (positivos/negativos).

Acciones

- Aumentar imágenes por clase y **balancear** positivos/negativos.
- Incorporar **más variación**: ángulos, distancia, iluminación, densidad de personas.
- Ajustar augmentations / revisar etiquetas (calidad GT).
- Probar **YOLOv8s** (mejor capacidad) y/o ajustar hiperparámetros.

Cierre

Siguiente iteración: foco en **mejorar recall** sin sacrificar demasiado precision.

Como prototipo cumple: pipeline y evidencia. El siguiente salto es robustez: más datos, mejor balance y un modelo un poco más capaz para subir recall.

- **Riesgo:** *Recall bajo → falsos negativos (incumplimientos no detectados).*
- **Acción:** *Priorizar subir recall en próximas iteraciones.*

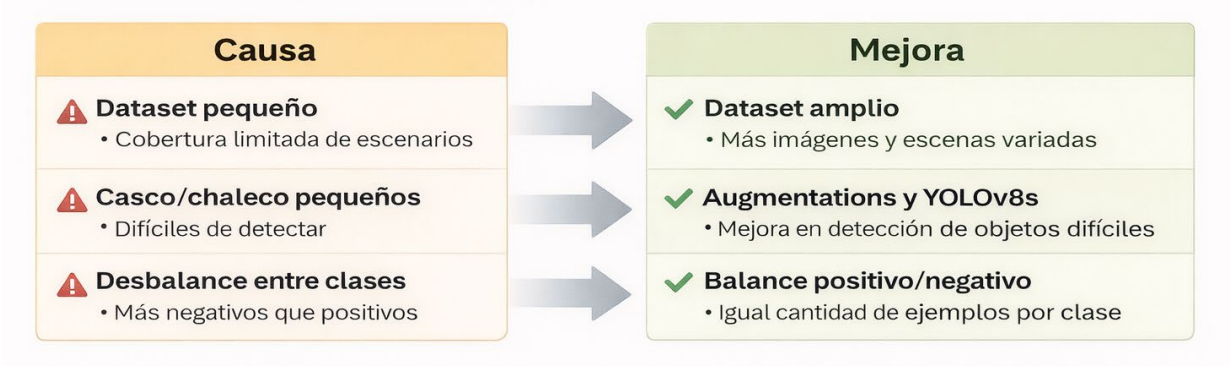

Ejemplos de predicción (inferencia)

Contenido

- 2–3 imágenes con bounding boxes (ideal: 1 ‘buena’, 1 ‘fallo típico’, 1 ‘escena nueva’)
- Debajo de cada imagen:
    - “Correcto: hardhat + safety_vest”
    - “Fallo: oclusión / distancia / iluminación”
    - “Generalización: escena distinta”

Esto muestra qué detecta bien y dónde falla. Sirve para decidir qué datos faltan.

Ejemplos ilustrativos (layout), outputs reales en notebook

Gobernanza y consideraciones (dataset/modelo)

• Licencia y atribución del dataset (Roboflow) + versionado.

• Uso previsto: apoyo a inspección, **no** reemplazo total de supervisión.

• Privacidad: evitar rostros/identificación personal si aplica; control de acceso a imágenes.

• Registro: mantener evidencia de métricas por versión (dataset vX → modelo vY).

Esto lo deja profesional: trazabilidad, cumplimiento y uso responsable del prototipo.